

MANEJO DE LA IA EN LA INVESTIGACIÓN BIOMÉDICA Y CIENCIAS DE LA SALUD




Diego Herráez Aguilar
Ramiro Perezzan Rodríguez




Objetivos

Teoría



Práctica



Reflexión



USO RESPONSABLE DE LA IA

Calendario del Curso



Día 1: Contexto e Introducción a la IA

Manejo de ChatBots, uso de CHATGPT como herramienta clave



Día 2: Herramientas de IA en investigación

- Incluye el uso de NotebookLM como herramienta clave



Día 3: Automatización y otras herramientas de interés

- Introducción a la automatización de procesos
- Integración de IA en flujos de trabajo

Programa del Día 1



Antecedentes



Funcionamiento de IA



Tipos de IA



Modelos de IA



Prompts



Herramientas en ChatGPT



Áreas de Mejora de la IA



Vocabulario IA



Impacto de la IA en el mundo

El maremoto de la IA



La IA protagonista del momento actual




Amplificación de las capacidades humanas



Nivel de exposición de las tareas a los modelos de lenguaje, por grupos ocupacionales

Porcentaje estimado de tareas de cada grupo ocupacional que podrían reducirse en un 50% o más con modelos de lenguaje de gran tamaño (LLM)



Fuente: Brookings Institution, 2024. Basado en análisis de exposición ocupacional a IA generativa a partir de datos de tareas.

Nota: La figura representa estimaciones del porcentaje de tareas de cada grupo ocupacional que podrían realizarse en la mitad de tiempo o menos con ayuda de modelos de lenguaje.

Perfil de Usuarios de IA



Hitos de la Inteligencia Artificial

COMIENZO DE LA IA:

Propuesta de
Alan Turing



1950

Propuesta de
Turing

CREACIÓN
DE ELIZA



1966

ELIZA

VICTORIA DE
DEEP BLUE



1997

Deep Blue vence
al campeón
mundial de
ajedrez

VICTORIA DE
ALPHAGO



2016

AlphaGo vence
al campeón
de Go

ARQUITECTURA
TRANSFORMER



2017

Nace la
Arquitectura
Transformer

Lanzamiento
de GPT-3




2020


Revolución de
Modelos de
Lenguaje
(GPT-3)




Tiempo de ahorro en tareas realizadas por la IA




Tiempo de ahorro en tareas realizadas por la IA




Tiempo de ahorro en tareas realizadas por la IA




Tiempo de ahorro en tareas realizadas por la IA



Tiempo de ahorro en tareas realizadas por la IA




Tiempo de ahorro en tareas realizadas por la IA






IA: un paraguas, no una aplicación




IA es un paraguas, no una herramienta.



Machine learning: aprender de ejemplos


No le damos todas las reglas: le damos ejemplos.




Deep learning: representar lo complejo

Texto · imagen ·
audio · señales ·
datos biomédicos

El deep learning aprende
representaciones, no solo reglas simples.



IA generativa: del análisis a la producción



Generar no significa garantizar verdad.

¿QUÉ ES UNA IA?

Un sistema que recibe datos, los procesa y genera un resultado.



Entrada

Análisis

Resultado



RECUERDA:

La IA no piensa como una persona: convierte una entrada en una salida mediante un procesamiento interno.

Regresión: el modelo más sencillo de IA


Regresión es un conjunto de métodos estadísticos utilizados para **modelar** y analizar la relación entre una variable dependiente (también llamada respuesta o salida) y una o más variables independientes (también llamadas explicativas o predictoras).

El error debe estar homogéneamente distribuido

$$\mathbb{E}[\varepsilon] = 0$$

Y la suma de sus cuadrados debe ser mínima

$$\sum_i |\varepsilon_i|^2$$




$$\underline{y} = \underline{f}(\underline{x_1, x_2, \dots, x_p}) + \underline{\varepsilon}$$

El objetivo principal de la regresión es estimar cómo cambia la variable dependiente en función de las independientes, permitiendo **realizar predicciones, identificar tendencias y comprender relaciones subyacentes en los datos**.

Si conocemos la dependencia ..

Regresión LINEAL por mínimos cuadrados




$$y = a + bx \quad \left\{ \begin{array}{l} y_{\text{obs}} \xrightarrow{f} x_{\text{pred}} \\ x \xrightarrow{f} y_{\text{pred}} \end{array} \right.$$

$$S(a, b) = \sum_i |\varepsilon_i|^2 \quad \text{MSE}$$


$$\beta = (a, b) = \arg \min \sum_i |\varepsilon_i|^2$$

$$\frac{\partial S}{\partial \beta} = -2X^\top (y - X\beta) = 0$$



Si conocemos la dependencia ..

La red neuronal más simple




**OPTIMIZACIÓN
(ENTRENAMIENTO)**

$$\vec{\nabla} S = \left(\frac{\partial S}{\partial a}, \frac{\partial S}{\partial b} \right)$$

$$(a_{n+1}, b_{n+1}) = (a_n, b_n) - l_r \cdot \vec{\nabla} S$$





Learning rate



Si conocemos la dependencia ..




La red neuronal más simple

$$y = a + bx$$





Si conocemos la dependencia ..

La red neuronal más simple



Si NO conocemos la dependencia ..

Las redes neuronales ya no pueden ser tan simples ...



QUÉ SIGNIFICA “CAJA NEGRA”

Cuando el resultado es visible, pero el razonamiento interno no lo es



NO TODA IA ES IGUAL DE OPACA

Del razonamiento explícito al modelo difícil de explicar


MÁS TRANSPARENTE

MÁS OPACO



Reglas clínicas

Razonamiento
explícito



**Árboles de
decisión**

Secuencia fácil
de seguir




**Regresión
logística**

Variables con
pesos



**Modelos
ensamblados**

Muchos modelos
combinados



**Redes
profundas**

Capas
múltiples



**Modelos de
lenguaje**

Texto plausible,
lógica difícil de
rastrear

Más complejo no siempre significa mejor; más transparente no siempre significa suficiente.

CÓMO APRENDE LA MÁQUINA

Tres formas de extraer patrones a partir de datos



SUPERVISADO

Aprende con ejemplos etiquetados.

Analogía: residente con tutor.

Ejemplo: riesgo de sepsis.




NO SUPERVISADO

Busca patrones sin etiquetas previas.

Analogía: investigador que agrupa casos.

Ejemplo: fenotipos de pacientes.



POR REFUERZO

Aprende con acciones y retroalimentación.

Analogía: ajustar según respuesta.


Ejemplo: decisiones secuenciales.

Predecir • descubrir patrones • optimizar decisiones

APRENDIZAJE SUPERVISADO

Descubrir patrones a partir de etiquetas

1. RECIBE EJEMPLOS




Se entrena con ejemplos ya etiquetados.

Cada caso tiene datos de entrada y una respuesta correcta.

Ejemplo: constantes + etiqueta 'riesgo alto' o 'riesgo bajo'.

2. APRENDE EL PATRÓN



Busca la relación entre los datos y la etiqueta.

Aprende qué señales se asocian a cada resultado.

Analogía: como estudiar casos ya corregidos por un tutor.

3. PREDICE CASOS NUEVOS



Después aplica lo aprendido a nuevos casos.

Genera una predicción o clasificación.

Ejemplo: estimar el riesgo de sepsis en otro paciente.

Aprende con etiquetas



Reconoce patrones



Predice nuevos casos

APRENDIZAJE SUPERVISADO

Cómo aprende y corrige errores una red neuronal

De la predicción inicial al ajuste progresivo del modelo



Predicción → error → ajuste → mejora



RECUERDA

Una red neuronal aprende corrigiendo errores de forma iterativa: predice, compara, ajusta pesos y vuelve a intentarlo.

APRENDIZAJE SUPERVISADO

RIESGOS DEL APRENDIZAJE SUPERVISADO

Cuando la IA aprende mal o no generaliza

1. ETIQUETAS ERRÓNEAS

Si la respuesta usada para entrenar es incorrecta, el modelo aprende una asociación equivocada.



ETIQUETA ASIRÓNADA

NO NEUMONÍA



- Diagnóstico mal registrado.
- Evento clínico mal codificado.
- Error en la anotación humana.
- Datos históricos incompletos.



EJEMPLO CLÍNICO


Radiografía de neumonía etiquetada erróneamente como "no neumonía".



Si la etiqueta está mal, el modelo aprende mal.

2. SESGO DE REPRESENTACIÓN

El modelo aprende solo de los pacientes que ve. Si el conjunto de datos no representa bien la población real, el rendimiento puede ser desigual.



- Poca diversidad de pacientes.
- Un único hospital o servicio.
- Infrarepresentación de grupos concretos.
- Diferencias de edad, sexo, etnia o complejidad clínica.



EJEMPLO CLÍNICO


Modelo entrenado en adultos de un hospital terciario y aplicado en población anciana o en otro entorno asistencial.



Si los datos no representan a los pacientes reales, el modelo puede no generalizar bien.

3. SOBREAJUSTE

El modelo aprende demasiado bien los detalles del conjunto de entrenamiento, incluso ruido o peculiaridades irrelevantes, y luego rinde peor con datos nuevos.



- Excelente rendimiento en entrenamiento.
- Peor rendimiento en validación externa.
- Memoriza patrones específicos.
- No generaliza a nuevos casos.



EJEMPLO CLÍNICO

Funciona muy bien en la base histórica del hospital, pero empeora en otro centro o en pacientes de un periodo distinto.




No basta con acertar en entrenamiento: debe funcionar también fuera de él.

APRENDIZAJE NO SUPERVISADO

Descubrir patrones sin etiquetas


La IA identifica grupos y relaciones ocultas en los datos sin conocer de antemano la respuesta correcta.



APRENDIZAJE AUTOSUPERVISADO

Sistemas de aprendizaje “autoetiquetados”

1. USA DATOS SIN ETIQUETAS




Parte de datos sin etiquetar.

No necesita que una persona indique la respuesta correcta.

El propio dato servirá para generar la señal de aprendizaje.

2. OCULTA UNA PARTE



Crea una tarea auxiliar o de pretexto.

Oculta o enmascara una parte de la información.

El modelo intenta predecir lo que falta usando el contexto.

3. PREDICE Y SE AJUSTA



Compara su predicción con el dato real.

Corrige sus parámetros para mejorar.

Así aprende patrones útiles sin etiquetas humanas.

Sin etiquetas manuales




Predice partes ocultas



Aprende del contexto

LARGE LANGUAGE MODELS (LLMs)

Anatomía de un modelo grande de lenguaje



COMPRENDER (humano)

- Integra conocimientos y experiencias previas
- Razonamiento causal y clínico
- Juicio, intención y criterios contextualizados



CALCULAR PATRONES (LLM)

- Detecta patrones estadísticos en texto
- Predice el siguiente token más probable
- No tiene conciencia ni comprensión clínica



Un LLM predice texto; no comprende fisiopatología.

LARGE LANGUAGE MODELS (LLMs)

TOKENIZACIÓN

Es el proceso por el cual un modelo de lenguaje divide el texto en unidades más pequeñas, llamadas tokens, para poder entenderlo y procesarlo.



RECUERDA:

Los tokens pueden ser palabras completas, partes de palabras o incluso signos de puntuación. La forma en que se tokeniza puede variar según el modelo de lenguaje.

<https://gemini.google.com/share/e31ea267f0c5>

Arquitectura Transformer (donde la clave está en el contexto)



El Transformer relaciona palabras a gran escala; no comprende causalidad clínica.



RECUERDA:

La autoatención permite que cada palabra “mire” al resto del texto para calcular qué partes son relevantes en ese contexto.

LARGE LANGUAGE MODELS (LLMs)


Generación de texto (probabilística)

1. DISTRIBUCIÓN PROBABILÍSTICA DE POSIBLES SIGUIENTES TOKENS

El modelo asigna probabilidades a todas las opciones posibles.

Entrada (contexto):
"El paciente presenta dolor torácico y..."

Posibles siguientes tokens



Las probabilidades se calculan sobre miles de tokens posibles en cada paso.

2. SELECCIÓN DEL TOKEN Y GENERACIÓN

El modelo selecciona un token (o muestrea) y continúa generando la secuencia.



1. Calcula probabilidad de todos los tokens posibles.



2. Selecciona o muestrea un token según los parámetros.



3. Añade el token elegido y repite el proceso con el nuevo contexto.



Salida (continuación del texto):

"El paciente presenta dolor torácico y **disnea**..."



El modelo calcula probabilidades; no razona clínicamente.

3. PARÁMETROS DE CONTROL

Influyen en la variabilidad, creatividad y riesgo de error de la respuesta.

TEMPERATURA BAJA



(Ej. 0.1 – 0.3)

- ✓ Respuesta más estable y predecible.
- ✓ Menos variabilidad.
- ✓ Más repetible.
- ✓ Menor creatividad.
- ✓ Más adecuada para entornos clínicos y sensibles.

TEMPERATURA ALTA



(Ej. 0.8 – 1.2)

- ✓ Más creatividad y diversidad.
- ✓ Mayor variabilidad.
- ✓ Menos repetible.
- ✓ Mayor riesgo de respuestas plausibles pero incorrectas.
- ✓ Menor seguridad clínica.

OTROS PARÁMETROS CLAVE



TOP-K

Limita la selección a los K tokens con mayor probabilidad (ej. k=40).



TOP-P (NÚCLEO)

Considera el conjunto mínimo de tokens cuya probabilidad acumulada alcanza p (ej. p=0.9).



Parámetros más amplios = más riesgo de alucinaciones y errores clínicamente relevantes.

LARGE LANGUAGE MODELS (LLMs)

El contexto es la información que el modelo usa para interpretar una petición y generar una respuesta adecuada.

1. ¿QUÉ ES?



- Pregunta, instrucciones y conversación previa.
- También puede incluir ejemplos y documentos.
- Define lo que el modelo tiene disponible en ese momento.

2. ¿POR QUÉ IMPORTA?



- Da significado a las palabras.
- Orienta la tarea y el objetivo.
- Reduce la ambigüedad.
- Mejora la precisión y la coherencia.

3. ¿QUÉ APORTA?



- Adapta el tono, el nivel y el formato.
- Ayuda a mantener continuidad en la conversación.
- Hace la respuesta más útil y verificable.
- Disminuye respuestas genéricas.

4. RIESGOS SI EL CONTEXTO ES INADECUADO



- Puede interpretar mal la petición.
- Genera respuestas generales o incompletas.
- Favorece suposiciones y alucinaciones.
- Puede omitir matices importantes.
- Da una falsa sensación de precisión.
- Puede reforzar el sesgo de confirmación.

Más claridad

Menos ambigüedad

Mejores respuestas



RECUERDA:

Cuanto mejor definido esté el contexto, más pertinente, controlable y segura será la respuesta del modelo.

LARGE LANGUAGE MODELS (LLMs)

Generación Aumentada por Recuperación (RAG)

Es una técnica en la que el modelo busca información relevante en fuentes externas y la usa como contexto antes de responder.

1. ¿QUÉ ES?



- Combina búsqueda y generación.
- El modelo no responde solo con lo que ya aprendió.
- Primero consulta documentos o bases de conocimiento.

2. ¿CÓMO FUNCIONA?



- El usuario hace una pregunta.
- El sistema recupera fragmentos relevantes.
- Esos fragmentos se añaden como contexto.
- Después el modelo genera la respuesta.

3. ¿QUÉ APORTA?



- Respuestas más específicas y actualizadas.
- Menos alucinaciones si las fuentes son buenas.
- Permite apoyarse en documentos propios.
- Mejora la trazabilidad de la información.

4. LÍMITES Y RIESGOS



- Depende de la calidad de la búsqueda.
- Si recupera mal, responderá peor.
- Puede omitir información relevante.
- No sustituye la verificación humana.

Busca información

Añade contexto

Genera mejor



RECUERDA:

La generación aumentada por recuperación mejora la respuesta porque el modelo no parte solo de su memoria: consulta fuentes y responde con ese apoyo.

LLM: fluidez no es autoridad



Parece saber

- Generan texto plausible en contexto



Requiere verificación


- No son una base de datos perfecta
- No son autoridad científica

La fluidez no es evidencia de verdad.

Cómo se construye un modelo útil




Los modelos heredan capacidades, límites y sesgos de sus datos.



Mejorar un modelo no es solo hacerlo más grande

Mejorar un modelo no es solo hacerlo más grande.




LA PIRÁMIDE DEL MODELO

no basta con mirar tokens por segundo




Multimodalidad: varios lenguajes de investigación



Multimodalidad significa trabajar con varios lenguajes a la vez.

Evolución de la IA



Presente

IA Débil

(Narrow AI)

Especializada en
tareas específicas



Futuro

IA Fuerte

(AGI)

Inteligencia comparable
a la humana




Futuro Lejano

Superinteligencia

(ASI)

Capacidades muy
superiores a las humanas

LA IA FALLA




Probabilidad:

resultados probabilísticos



Temperatura:

Medida de rigidez de los modelos




Alucinaciones:

errores de las IA's

EL USUARIO ES EL EXPERTO

QUE DEBEMOS EXIGIR A LOS MODELOS DE IA



Evitar el Sobreajuste

Generalización y Prevención de Memorización

Evitar que el modelo aprenda ruidos específicos y 'memorice' los datos, asegurando que pueda predecir bien en nuevos datos.



Reducción del Sesgo

Garantizar la Equidad y Representatividad

Corregir sesgos en los datos de entrenamiento para asegurar que el modelo trate de manera justa a todos los grupos de población.



Comprensión Interna

Transparencia y Trazabilidad del Modelo

Entender exactamente cómo y por qué el modelo toma decisiones, analizando su arquitectura y el flujo de datos internos.





Explicación Externa

Justificación y Comunicación de Decisiones

Proporcionar explicaciones claras y accesibles en lenguaje natural sobre las decisiones del modelo, especialmente en casos complejos, para aumentar la confianza humana.

MULTITUD DE MODELOS DE LLM



LA GRAN CARRERA DE LAS IA EN EL SALVAJE OESTE!

¡A LA CONQUISTA
DEL TERRENO!

TERRENO DE
OPORTUNIDAD

TERRENO DE
OPORTUNIDAD



¡LA COMPETENCIA
ES FERROZ!

Benchmarks

Metrics	Opus 4.8	Opus 4.7	GPT-5.5	Gemini 3.1 Pro
Agentic coding SWE-Bench Pro	69.2%	64.3%	58.6%	54.2%
Agentic terminal coding Terminal-Bench 2.1	74.6%	66.1%	78.2%	70.3%
Multidisciplinary reasoning Humanity's Last Exam	49.8% no tools	46.9% no tools	41.4% no tools	44.4% no tools
	57.9% with tools	54.7% with tools	52.2% with tools	51.4% with tools
Agentic computer use OSWorld-Verified	83.8%	82.8%	78.7%	76.2%
Knowledge work GDPval-AA	1890	1753	1769	1314
Agentic financial analysis Finance Agent v2	53.9%	51.5%	51.8%	43.0%


Artificial Analysis Intelligence Index

Artificial Analysis Intelligence Index v4.0 incorporates 10 evaluations: GDPval-AA, r^2 -Bench Telecom, Terminal-Bench Hard, SciCode, AA-LCR, AA-Omniscience, IFBench, Humanity's Last Exam, GPQA Diamond, CritPt

28 of 527 models

[+ Add model from specific provider](#)

Artificial Analysis



💡 Reasoning models are indicated by a lightbulb icon

Ecosistema de modelos: elegir según la tarea


	Cerrados (APIs)	Abiertos	Locales
Privacidad de Datos	 Datos No Seguros (Potencial Exposición)	 Depende de la Implementación (Riesgo Variable)	 Perfectamente Seguro (Control Total)
Coste Computacional	 Alto (Pago por Uso)	 Moderado (Infraestructura Propia)	 Bajo (Hardware Propio)
Capacidad de Razonamiento	 Muy Alta (SOTA)	 Alta (Varía por Modelo)	 Media/Baja (Limitado por Recursos)
Control / Trazabilidad	 Mínimo (Caja Negra)	 Parcial (Configurable)	 Máximo (Transparente)

Modos de Despliegue Adicionales:

Generalistas | Especializados | Agentes

No existe el mejor modelo en abstracto.

Costes invisibles: datos, ética e infraestructura



La IA no vive en la nube: **vive en centros de cálculo.**



Prompting

Ingenier@s de Prompts

SHIT IN = SHIT OUT

SISO

Iteración

Fórmula Prompting



Guía Interactiva: 20 Trucos para Prompts

RECUERDA

1. Es importante verificar siempre la información proporcionada


2. Recibir diferentes respuestas al hacer la misma pregunta, no es un error

HERRAMIENTAS AVANZADAS


CHATGPT




CANVAS




CODE INTERPRETER




IMAGEN



VISIÓN



SEARCH



DEEP RESEARCH